

# 广义线性模型

XIONG XIONG

2021 年 12 月 26 日

# 目录

第一章 广义线性模型	1
1.1 引入	1
1.2 指数分布族	2
1.3 广义线性模型的结构	2
1.4 得分函数与信息矩阵	3
1.5 附注（一些推导）	6
1.6 参考资料 & 一些题外话	7

# 第一章 广义线性模型

## 概述

现有一随机变量 (也可以是向量)  $Y$  与  $p$  维变量  $X = (X_1, \dots, X_p)$ , 两者之间存在这某种统计关系, 其中  $Y$  是来自由某一列参数  $\gamma = (\theta, \phi)$  确定的分布族 (此处我们讨论指数分布族),  $X$  对  $Y$  的影响体现在  $\gamma = (\theta, \phi)$  中的  $\theta$  上, 具体的有映射  $K: \mathcal{X} \rightarrow \Theta, \theta = K(X)$ , 而  $\phi$  的取值与  $X$  无关, 为讨厌参数. 对给定的  $X$ , 我们可以确定  $\Theta$ , 同时如果对  $\phi$  存在某些假设 (如线性回归中的  $\sigma^2$  为常数), 就可以确定  $Y$  的分布.

但是映射  $K$  的具体形式往往是不知道的, 其未知性包含两点: 1.  $\theta$  与  $X$  之间是一种什么关系 (线性、二次、logit...); 2.  $\theta$  与  $X$  之间满足这种关系后某些系数的取值.

由于  $K(x_1, \dots, x_p)$  是一个  $p$  元函数, 对多元函数的处理是非常麻烦的, 我们希望对  $x = (x_1, \dots, x_p)$  作某种变换, 得到更好处理的单一变元  $\eta$  再与  $\theta$  建立联系. 很直观的想法是对  $X$  作线性假设, 令  $\eta = X\beta$ . (这种做法实用性很广泛, 在线性回归中我们发现很多关系都可以转化成线性关系 (如多项式、乘积式作对数变换等, 参见非线性回归)) 这里我们研究一类基于线性关系建立起的模型, 即  $K(x) = h(\eta) = h(X\beta)$ .

于是我们只需要选取某个特定的映射对  $\theta$  与  $\eta$  建立联系 (注意, 这个联系是人为选取的, 不同的联系会产生不同的模型, 甚至某些选取完全是错误的, 比如对指数模型作线性回归, 无论作什么处理都不会得到很好的拟合结果), 就可以建立  $Y$  与  $X$  之间的联系, 而整个模型中需要估计的参数只有  $\beta$ .

理解广义线性模型的核心在于理解各个变量的含义及其相互的联系, 其他内容基本都是多元情形下的数理统计的概念. 因此在这里先列出各个记号及映射关系, 其中可能有部分变量和函数在概述中没有提及, 在后续会展开解释.

$$\begin{array}{ccccccc}
 & & \xi = \mu^{-1}(h(\eta)) & & & & \\
 & & \curvearrowright & & \curvearrowleft & & \\
 \mathbf{X} & \xrightarrow{\eta = X\beta} & \eta & \xleftrightarrow[h(\eta)]{g(\mu)} & \mu & \xleftrightarrow[b'(\theta)]{\mu^{-1}} & \theta \longrightarrow l(Y, \theta) \\
 q \times p & & q \times 1 & & q \times 1 & & q \times 1
 \end{array}$$

## 1.1 引入

在一般线性回归中, 响应变量  $Y$  与设计矩阵  $\mathbf{X}$  之间存在着统计关系

$$Y = \mathbf{X}\beta + \epsilon$$

其中  $\mathbb{E}[\epsilon_i] = 0, \text{Cov}[\epsilon] = \sigma^2 I$ , 特别的可取  $\epsilon \sim N_p(\mathbf{0}, \sigma^2 I)$ .

对上述模型, 可以有另一种理解:

$$Y_i \sim N(\mu_i, \sigma^2) \quad \mathbb{E}[Y_i] = \mu_i \quad \mu_i = \eta_i = X_i \beta \quad (1.1)$$

这里我们引入了变量  $\eta_i = X_i\beta$ , 来表示自变量  $X_i$  在  $\beta$  下的线性组合.

从而我们希望当  $Y$  不再服从正态分布, 而是其他某种已知的分布时, 建立  $Y$  与  $\eta = X\beta$  之间的一种联系? 考虑到  $Y$  是一个随机变量, 因此需要寻找一个与  $Y$  相关的定量来描述  $Y$  的特性, 因此模仿线性回归, 我们希望建立  $\mathbb{E}[Y]$  与  $\eta$  之间的关系. 因此我们将1.1改写称如下形式

$$Y_i \sim f(\theta, \phi) \quad \mathbb{E}[Y_i] = \mu_i \quad g(\mu_i) = \eta_i = X_i\beta \quad (1.2)$$

上述三个元素就组成了广义线性模型 (后续会对这三个元组给出具体说明).

## 1.2 指数分布族

为便于建立各个变量与参数之间的关系 (求导、求期望等), 广义线性模型要求随机变量  $Y$  的分布来自指数分布族. 在介绍广义线性模型前, 我们先来考察一些指数分布族的一些性质

**定义 1.1.** 称随机向量  $Y$  来自指数分布族, 若其概率密度函数可以写成

$$f_Y(y, \theta) = a(\theta)b(y) \exp\{y'Q(\theta)\}$$

一个更一般的参数化密度函数允许包含一些讨厌参数或扩散参数  $\phi$ . 此时我们将其密度函数写称如下形式

$$f(y; \theta, \phi) = \exp \left\{ \frac{y'\theta - b(\theta)}{a(\phi)} + c(\phi, y) \right\} \quad (1.3)$$

其中  $\theta \in \Theta \subset \mathbb{R}^q$  称为自然参数;  $\phi$  未知, 称为扩散参数或讨厌参数. 对给定的  $\phi$  称  $\Theta$  为自然参数空间, 即所有满足下式的集合

$$0 < \int \exp\{y'\theta/a(\phi) + c(\phi, y)\} dy < \infty$$

此时  $\Theta$  是凸的.

**定理 1.1.** 若  $Y$  来自上述指数分布族, 则

$$\mathbb{E}_\theta[Y] = \frac{\partial b(\theta)}{\partial \theta} \quad \text{Cov}_\theta[Y] = a(\phi) \frac{\partial^2 b(\theta)}{\partial \theta \partial \theta'} \triangleq \Sigma(\theta) \quad (1.4)$$

## 1.3 广义线性模型的结构

一个 GLM 由三个部分组成, 在介绍这三个部分时, 我们先对我们拥有的观测结数据做一些解释:  $X = \{X_1, \dots, X_N\}$  是我们收集到的  $N$  个  $q \times p$  维的协变量 (有一些书中将  $X$  定义为不含常数 1 列的变量, 而用  $Z$  表示  $(1, X)$ , 而此处, 我们的  $X$  与  $Z$  表示同一个量), 与之对应的有  $N$  个  $q \times 1$  维的观测结果  $Y = \{Y_1, \dots, Y_N\}$ .

这其实是我们常见的数据的推广, 在学习回归的过程中, 我们接触到的往往是  $N$  个 1 维的响应变量  $Y$ , 以及  $N$  个  $p$  维的协变量  $X$ , 即上述数据中取  $q = 1$  的情形. 实际上, 我们接触到的大部分模型都是  $p = 1$  的, 但为了让我们的模型更具泛用性, 我们直接研究  $p \geq 1$  时的情形.

下面我们来看 GLM 的三个部分:

1. 随机部分: 建立起了  $l(\theta, Y_i)$  与  $\theta$  以及  $\mu$  之间的联系.

随机部分的  $Y$  由  $N$  个观测值  $Y = \{Y_1, \dots, Y_N\}$  组成. 每个  $Y_i$  相互独立且来自相同  $q \times 1$  维未知参数  $\theta$  决定的指数分布族. 考虑单个随机向量  $Y_i$  的指数分布族, 并结合1.1则有

$$\mu_i \triangleq \mathbb{E}[Y_i] = \frac{\partial b_i(\theta)}{\partial \theta} = \left( \frac{\partial b_i}{\partial \theta_1}, \dots, \frac{\partial b_i}{\partial \theta_q} \right)'$$

## 2. 系统部分: 这一部分建立起了 $X$ 与 $\eta$ 之间的联系.

系统部分是一组解释变量构成的线性模型

$$\eta_i = X_i \beta$$

其中  $\eta_i$  叫做线性预报;  $X_i$  是  $q \times p$  维矩阵 ( $i = 1, \dots, N$ ), 是对解释变量的一组观测值;  $\beta$  是一组  $p$  维未知常向量.

## 3. 连接函数: 这一部分建立起了 $\mu$ 与 $\eta$ 之间的联系

记  $\mathbb{E}[Y_i] = \mu_i$  则连接函数可写作

$$g(\mu_i) = \eta_i = X_i \beta \quad i = 1, \dots, N$$

其中  $g: \mathcal{H} \rightarrow \mathbb{R}^q, \mathcal{H} \subset \mathbb{R}^q$  是一个可逆且可微的函数 (在一元情形下往往取作单调函数).

又由  $g(\mu)$  可逆可微知其存在反函数  $h: \mathbb{R}^q \rightarrow \mathcal{H}, h(\eta) = g^{-1}(\eta)$ , 称为响应函数.

当  $g(\mu)$  与  $\mu = b'(\theta)$  都给定时, 我们还能直接写出  $\eta \rightarrow \theta$  的映射  $\xi(\eta)$ .

$g(\mu)$  的几个特殊情形:

- (1) 自连接 (identity link):  $g(\mu) = \mu$
- (2) 自然连接 (canonical link):  $g(\mu(\theta)) = \theta$ . 由 1.1 知, 自然连接满足  $g(\mu_i) = b'^{-1}(\mu_i)$ .

下面给出一些自然函数习惯上的选取方式:

- (1) 如果响应变量的观察值是连续型数据, 同时又比较对称, 这时可以假定随机变量来自于正态总体.
- (2) 如果选择正态总体而连结函数是自然连结函数, 这就成了普通的线性回归 (读者可自行验证以加强对自然连接函数的理解).
- (3) 如果响应变量的观察值是非负的连续型数据, 则可应用  $\Gamma$  分布来构造广义线性回归模型.
- (4) 如果数据是非对称的生命数据, 就可以应用逆高斯分布来构造广义线性回归模型.

## 1.4 得分函数与信息矩阵

首先我们需要对模型作一些必要的假设:

- $\beta$  的可容许参数空间  $B$  是开的
- 对所有参数  $\beta \in B, \mathbf{h}(Z_i \beta) \in y$  其中  $i = 1, 2, \dots, Z_i$  为  $q \times p$  的设计矩阵 (这里我们不再用  $X_i$ , 而是使用  $Z_i$ !!!),  $y$  为  $Y$  的均值取值空间.
- $\mathbf{h}, g$  与  $\xi$  是二阶可微的, 且  $\det(\partial g / \partial \eta) \neq 0$ .
- 对足够大的  $n, \sum_{i=1}^n Z_i Z_i'$  满秩.

这一块由于主要就是计算, 所以基本就是抄周勇老师的广义估计方差估计方法 P244-246 的内容, 但由于这部分内容比较简略, 会在文末会对  $S_i(\beta)$  与  $F_i(\beta)$  的推导作出一些解释.

考察  $Y$  的似然函数 (likelihood function)

$$L(\theta, \phi; Y) = \prod_{i=1}^N \exp \left\{ \frac{\mathbf{Y}_i' \boldsymbol{\theta}_i - b(\boldsymbol{\theta}_i)}{a(\phi)} + c(\mathbf{Y}_i, \phi) \right\} \quad (1.5)$$

其对数似然函数可以写成

$$l(\theta, \phi; Y) = \sum_{i=1}^N \left\{ \frac{\mathbf{Y}_i' \boldsymbol{\theta}_i - b(\boldsymbol{\theta}_i)}{a(\phi)} + c(\mathbf{Y}_i, \phi) \right\} \quad (1.6)$$

对数似然函数对  $\theta$  的一阶导函数组成的向量函数称为得分函数 (score function) .

$$\mathbf{S}(\boldsymbol{\theta}) = \frac{\partial l}{\partial \boldsymbol{\theta}} = \sum_{i=1}^N \mathbf{S}_i(\boldsymbol{\theta}_i) \quad (1.7)$$

将  $a(\phi)$  视作讨厌参数, 于是得到相应的估计方程:

$$\frac{\partial l}{\partial \boldsymbol{\theta}} = \sum_{i=1}^N \frac{Y_i - \boldsymbol{\mu}_i}{a_i(\phi)} = 0 \quad (1.8)$$

而在实际的广义线性模型中, 我们感兴趣的是未知参数  $\boldsymbol{\beta}$ , 每个观测值  $Y_i$  对  $\boldsymbol{\beta}$  的对数似然作出的贡献可记为

$$l_i(\boldsymbol{\beta}) = [Y_i' \boldsymbol{\theta}_i - b(\boldsymbol{\theta}_i)] / a_i(\phi) \quad (1.9)$$

每个个体关于  $\boldsymbol{\beta}$  的得分函数为  $\mathbf{S}_i(\boldsymbol{\beta}) = \partial l_i / \partial \boldsymbol{\beta}$  由此可得

$$\begin{aligned} \mathbf{S}_i(\boldsymbol{\beta}) &= \frac{\partial \mathbf{h}(Z_i \boldsymbol{\beta})}{\partial \boldsymbol{\beta}} \Sigma_i^{-1}(\boldsymbol{\beta}) (Y_i - \boldsymbol{\mu}_i(\boldsymbol{\beta})) \\ &= Z_i' D_i(\boldsymbol{\beta}) \Sigma_i^{-1}(\boldsymbol{\beta}) (Y_i - \boldsymbol{\mu}_i(\boldsymbol{\beta})) \end{aligned} \quad (1.10)$$

其中  $D_i(\boldsymbol{\beta}) = \frac{\partial \mathbf{h}(\boldsymbol{\eta})}{\partial \boldsymbol{\eta}}$  是  $\mathbf{h}(\boldsymbol{\eta})$  的雅可比矩阵在  $\boldsymbol{\eta}_i = Z_i \boldsymbol{\beta}$  的值,  $\Sigma_i(\boldsymbol{\beta}) = v(\mathbf{h}(Z_i \boldsymbol{\beta})) a_i(\phi)$ . 上式还可以等价地写为

$$\mathbf{S}_i(\boldsymbol{\beta}) = Z_i' W_i(\boldsymbol{\beta}) \frac{\partial \mathbf{g}(\boldsymbol{\mu}_i)}{\partial \boldsymbol{\mu}'} (Y_i - \boldsymbol{\mu}_i(\boldsymbol{\beta})) \quad (1.11)$$

其中  $W_i$  是一个权矩阵

$$W_i(\boldsymbol{\beta}) = \left[ \frac{\partial \mathbf{g}(\boldsymbol{\mu}_i)}{\partial \boldsymbol{\mu}'} \Sigma_i(\boldsymbol{\beta}) \frac{\partial \mathbf{g}(\boldsymbol{\mu}_i)}{\partial \boldsymbol{\mu}} \right]^{-1} = D_i \Sigma_i^{-1} D_i' \quad (1.12)$$

由此只需求解方程

$$\mathbf{S}(\boldsymbol{\beta}) = \frac{\partial l}{\partial \boldsymbol{\beta}} = \sum_{i=1}^N \frac{\partial l_i}{\partial \boldsymbol{\beta}} = \sum_{i=1}^N \mathbf{S}_i(\boldsymbol{\beta}) = 0 \quad (1.13)$$

即可得到  $\boldsymbol{\beta}$  的极大似然估计  $\hat{\boldsymbol{\beta}}_n$ .

### 得分函数及 Fisher 信息阵的性质

下面考察得分函数及其 Fisher 信息阵的一些性质首先对  $\mathbf{S}_i$ , 其期望为 0:

$$\mathbb{E}_{\boldsymbol{\beta}} \mathbf{S}_i(\boldsymbol{\beta}) = Z_i' D_i(\boldsymbol{\beta}) \Sigma_i^{-1}(\boldsymbol{\beta}) (\mathbb{E}[Y_i] - \boldsymbol{\mu}_i(\boldsymbol{\beta})) = 0 \quad (1.14)$$

该统计结构的 Fisher 信息阵或期望信息阵为

$$F_i(\boldsymbol{\beta}) = \text{Cov}_{\boldsymbol{\beta}}(\mathbf{S}_i(\boldsymbol{\beta})) = \mathbb{E}_{\boldsymbol{\beta}}(\mathbf{S}_i(\boldsymbol{\beta}) \mathbf{S}_i'(\boldsymbol{\beta})) = Z_i' W_i Z_i \quad (1.15)$$

观察信息阵为

$$F_{i,obs}(\beta) = -\frac{\partial^2 l_i}{\partial \beta \partial \beta'} = F_i(\beta) - \frac{1}{a(\phi)} R_i(\beta) \quad (1.16)$$

其中

$$R_i(\beta) = \sum_{r=1}^q Z_i' U_{ir} Z_i (y_{ir} - \mu_{ir}(\beta)) \quad (1.17)$$

其中  $U_{ir} = \frac{\partial^2 \xi_i(Z_i \beta)}{\partial \eta \partial \eta'}$  为  $q \times q$  矩阵. (注意, 1.16 中  $F$  的表达式与很多介绍 GLM 的书都不同, 多了一项  $a(\phi)^{-1}$ , 这一点将会在附注中说明.)

易证

$$\mathbb{E}_\beta[R_i(\beta)] = 0 \quad \mathbb{E}_\beta[F_{i,obs}(\beta)] = 0$$

由此可以证明在前述假设条件成立的情况下, 通过极大似然估计得到的  $\hat{\beta}_{ML}$  是  $\beta$  的相合估计, 且具有渐近正态分布.

**定理 1.2.** 假设前述条件成立, 则

$$\begin{aligned} \hat{\beta}_n &\xrightarrow{P} \beta \\ \sqrt{n}(\hat{\beta}_n - \beta) &\xrightarrow{D} N(0, \Sigma^{-1}(\beta)) \end{aligned}$$

其中  $\Sigma(\beta) = \lim_{n \rightarrow \infty} n^{-1} \sum_{i=1}^n Z_i' W_i Z_i$ .

这一部分本质上就是多元里的 MLE 的性质, 因此不展开具体证明.

可见 MLE 是对 GLM 中参数  $\beta$  的一个较好的估计.

#: 先介绍到这里吧, 后续随缘写一些假设检验和其他方面的拓展, 可能还会对二项分布展开介绍一下 (毕竟全篇没有例子). 属实是不想再敲笔记了 23333

另外, 别跑, 后面还有附注的证明. 敲了半天的公式 ==

## 1.5 附注 (一些推导)

证明. 定理 1.1

$$\begin{aligned}\frac{\partial \ln f}{\partial \boldsymbol{\theta}} &= \frac{1}{f} \frac{\partial f}{\partial \boldsymbol{\theta}} = \frac{1}{a(\phi)} \left\{ \mathbf{y} - \frac{\partial b(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \right\} \\ \frac{\partial^2 \ln f}{\partial \boldsymbol{\theta}^2} &= \frac{1}{f^2} \left[ \frac{\partial^2 f}{\partial \boldsymbol{\theta}^2} - \left( \frac{\partial f}{\partial \boldsymbol{\theta}} \right)^2 \right] = -\frac{1}{a(\phi)} \frac{\partial^2 b(\boldsymbol{\theta})}{\partial \boldsymbol{\theta} \partial \boldsymbol{\theta}^\top}\end{aligned}$$

从而由正则化假设有

$$\begin{aligned}\mathbb{E}[Y] &= \int \mathbf{y} f d\mathbf{y} = \int a(\phi) \frac{\partial f}{\partial \boldsymbol{\theta}} d\mathbf{y} + \frac{\partial b(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = \frac{\partial b(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \\ \text{Cov}[Y] &= \mathbb{E}(Y - \frac{\partial b(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}})^2 = \int \left( \mathbf{y} - \frac{\partial b(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} \right)^2 f d\mathbf{y} \\ &= \int \frac{a^2}{f^2} \left( \frac{\partial f}{\partial \boldsymbol{\theta}} \right)^2 f d\mathbf{y} = \int a^2 \left( \frac{\partial^2 f}{\partial \boldsymbol{\theta}^2} + \frac{f}{a(\phi)} \frac{\partial^2 b}{\partial \boldsymbol{\theta}^2} \right) d\mathbf{y} = a(\phi) \frac{\partial^2 b}{\partial \boldsymbol{\theta}^2}\end{aligned}$$

证明. 得分函数与 Fisher 信息阵相关的等式推导. 主要为 1.10, 1.16.

直接给出详细的证明往往是不讨喜的, 因此这部分建议自己推导.

首先我们列出几个的一阶偏导结果, 这些结果会在推导中反复用到 (注, 为方便书写, 将所有下标略去, 且不再对向量可以加粗 (因为实在太费时间了!))

$$\frac{\partial l}{\partial \theta'} = \left( y' - \frac{\partial b}{\partial \theta'} \right) / a(\phi) \quad (1.18)$$

$$\frac{\partial \theta}{\partial \mu'} = \left( \frac{\partial \mu}{\partial \theta'} \right)^{-1} = \left( \frac{\partial^2 b}{\partial \theta \partial \theta'} \right)^{-1} = a(\phi) \Sigma^{-1} \quad (1.19)$$

$$\frac{\partial \mu}{\partial \eta'} = D'(\beta) \quad (1.20)$$

$$\frac{\partial \eta}{\partial \beta'} = Z \quad (1.21)$$

其中 1.19 中用到了逆映射定理. 于是由链式法则, 有

$$\begin{aligned}S(\beta) &= \frac{\partial l}{\partial \beta} = \left( \frac{\partial l}{\partial \beta'} \right)' = \left( \frac{\partial l}{\partial \theta'} \frac{\partial \theta}{\partial \mu'} \frac{\partial \mu}{\partial \eta'} \frac{\partial \eta}{\partial \beta'} \right)' \\ &= Z' D \Sigma^{-1} (y - \mu(\beta))\end{aligned} \quad (1.22)$$

同时上面的式子还可以写成

$$\frac{\partial l}{\partial \beta} = \left( \frac{\partial l}{\partial \theta'} \frac{\partial \theta}{\partial \eta'} \frac{\partial \eta}{\partial \beta'} \right)' = Z' \left( \frac{\partial \xi}{\partial \eta'} \right)' \left( y - \frac{\partial b}{\partial \theta} \right) / a(\phi) \quad (1.23)$$

其中可记

$$\left( \frac{\partial \xi}{\partial \eta'} \right)' = \begin{bmatrix} \frac{\partial \xi_1}{\partial \eta_1} & \cdots & \frac{\partial \xi_n}{\partial \eta_1} \\ \vdots & & \vdots \\ \frac{\partial \xi_1}{\partial \eta_n} & \cdots & \frac{\partial \xi_n}{\partial \eta_n} \end{bmatrix} = \left( \frac{\partial \xi_1}{\partial \eta}, \dots, \frac{\partial \xi_q}{\partial \eta} \right)$$



又记  $y - \mu = \tau = (\tau_1, \dots, \tau_q)'$ , 则有

$$\begin{aligned} F_{i,obs}(\beta) &= -\frac{\partial^2 l}{\partial \beta \partial \beta'} = -\frac{\partial}{\partial \beta'} \left( \frac{\partial l}{\partial \beta} \right) \\ &= -Z' \sum_{i=1}^q \left( \tau_i \frac{\partial^2 \xi_i}{\partial \eta \partial \beta'} - \frac{\partial \xi_i}{\partial \eta} \frac{\partial \tau_i}{\partial \beta'} \right) / a(\phi) \\ &= -Z' \left( \sum_{i=1}^q \left( \tau_i \frac{\partial^2 \xi_i}{\partial \eta \partial \eta'} \frac{\partial \eta}{\partial \beta'} \right) + \left( \frac{\partial \xi}{\partial \eta'} \right)' \frac{\partial \tau}{\partial \beta'} \right) / a(\phi) \end{aligned} \quad (1.24)$$

其中

$$\frac{\partial \xi}{\partial \eta'} = \frac{\partial \theta}{\partial \mu'} \frac{\partial \mu}{\partial \eta'} = a(\phi) \Sigma^{-1} D' \quad (1.25)$$

$$\frac{\partial \tau}{\partial \beta'} = -\frac{\partial \mu}{\partial \beta} = -\frac{\partial \mu}{\partial \theta'} \frac{\partial \theta}{\partial \beta'} = -D' Z \quad (1.26)$$

代回 1.24, 即有

$$\begin{aligned} F_{i,bos}(\beta) &= Z' D \Sigma^{-1} D Z - \frac{1}{a(\phi)} \sum_{r=1}^q Z' \frac{\partial^2 \xi_r}{\partial \eta \partial \eta'} Z (y_r - \mu_r) \\ &= F_i(\beta) - \frac{1}{a(\phi)} R_i(\beta) \end{aligned} \quad (1.27)$$

没错这里与很多介绍 GLM 的书不同, 最终推导得到的公式中  $R$  项会多出一个系数  $a(\phi)^{-1}$ . 最早可以追溯到 [Fahrmeir-Tutz,1994] 的著作中的附录 A, 那里就有遗漏. 当然可以去查看更原始的文献 [Nelder and Wedderburn,1972], 在另一种指数分布族的表达中建立了信息量的表达式, 目测那里的推导没有遗漏任何系数.

## 1.6 参考资料 & 一些题外话

如果想系统地学习建议从 C. Radhakrishna Rao 入手, 作者从  $Y$  为一元随机变量入手开始介绍, 并举了很多常用的例子, 如果觉得有学习多元情形的需求, 再考虑阅读 Fahrmeir and Tutz 的书, 毕竟那本题目就有 multivariate.

参考资料在这里列出, 因为实在懒, 就没搞严格的引用格式.

[Fahrmeir and Tutz,1994] Book Multivariate Statistical Model (Append A)

[Nelder and Wedderburn,1972] Generalized Linear Models

[C. Radhakrishna Rao, 1999] Generalized Linear Models (Chap 10)

[周勇,2013] 广义估计方程估计方法 (Chap 11)